Akademia Górniczo-Hutnicza

im. Stanisława Staszica w Krakowie

Klasyfikacja tkanek w oparciu o sygnały wibroakustyczne do celów nawigacji urządzeń medycznych

Projekt z przedmiotu *Informatyka medyczna*

Prowadzący:	Szymon Sieciński
Autorzy:	Martyna Sokołowska
	Ryszard Nowak
Wydział:	Informatyki
Kierunek:	Informatyka
Specjalność:	Data Science

Kraków, 2025

Spis treści

Abstrakt **2**
1. Wstęp **3**
1.1 Cele i założenia projektu 4
1.2 Zarys ogólny proponowanego rozwiązania 4
1.3 Wykorzystany zbiór danych 4
1.4 Zawartość 5
2. Koncepcja proponowanego rozwiązania **5**
2.1 Przekształcenie danych 7
2.2 Wydobycie cech dźwięku 7
2.3 Redukcja wymiarowości 7
2.4 Trening modelu 8
2.5 Ewaluacja 8
3. Realizacja proponowanego rozwiązania **9**
3.1 Środowisko i narzędzia 9
3.2 Implementacja poszczególnych etapów 9
3.2.1 Przekształcenie danych 9
3.2.2 Wydobycie cech dźwięku 10
3.2.3 Redukcja wymiarowości 11
3.2.4 Trening modelu 12
3.2.5 Ewaluacja 13
3.3 Napotkane problemy 13
4. Rezultaty i wnioski **15**
4.1 Wizualizacja danych i redukcja szumu 15
4.2 Dobór metod i parametrów 16
4.3 Ewaluacja modelu 18
4.4 Wnioski 20
5. Podsumowanie **20**
Bibliografia **22**
DODATEK A: Kod źródłowy **23**

Abstrakt

Celem niniejszej pracy było zaprojektowanie i implementacja rozwiązania umożliwiającego klasyfikację materiałów na podstawie ich charakterystyki akustycznej. Projekt zakładał analizę dźwięków rejestrowanych podczas fizycznego kontaktu igły z materiałem i określenie, z jakiego tworzywa wykonany był badany obiekt.

W tym celu zastosowano szereg metod przetwarzania danych dźwiękowych, w tym wstępne filtrowanie, ekstrakcję cech akustycznych oraz redukcję wymiarowości danych. Następnie dane zostały poddane klasyfikacji z wykorzystaniem prostego modelu uczącego się na wcześniej oznaczonych przykładach.

Opracowane rozwiązanie osiągnęło wysoką skuteczność klasyfikacji materiałów, a uzyskane wyniki wykazały, że odpowiednio przetworzone dane dźwiękowe zawierają wystarczającą ilość informacji umożliwiających rozróżnienie klas. Analiza wyników wykazała także, że wybór cech i parametrów przetwarzania znacząco wpływa na jakość końcowej klasyfikacji.

Przeprowadzona praca potwierdza, że możliwe jest zastosowanie metod uczenia maszynowego w analizie dźwięku do automatycznego rozpoznawania materiałów, co może mieć zastosowanie m.in. w medycynie, przemyśle lub kontroli jakości.

Słowa kluczowe: analiza dźwięku, klasyfikacja materiałów, uczenie maszynowe, redukcja wymiarowości, ekstrakcja cech

1. Wstęp

Jednym z kluczowych wyzwań w minimalizacji inwazyjności zabiegów jest skuteczna nawigacja narzędzi medycznych w obrębie tkanek ludzkiego ciała, z jednoczesnym ograniczeniem uszkodzeń zdrowych struktur. W tym kontekście rośnie zainteresowanie wykorzystaniem sygnałów wibroakustycznych jako nieinwazyjnego źródła informacji o charakterystyce otaczających tkanek.

Sygnały wibroakustyczne, generowane podczas kontaktu narzędzi z różnymi rodzajami tkanek, zawierają unikalne cechy, które mogą być wykorzystane do ich rozróżniania. Analiza tych sygnałów przy pomocy metod przetwarzania sygnałów i technik uczenia maszynowego umożliwia automatyczną klasyfikację tkanek. Takie podejście otwiera nowe możliwości w zakresie inteligentnych systemów nawigacyjnych, wspierających lekarzy w prowadzeniu precyzyjnych zabiegów.

1.1 Cele i założenia projektu

Celem projektu jest opracowanie systemu klasyfikacji tkanek na podstawie zarejestrowanych sygnałów wibroakustycznych. Projekt obejmuje wstępne przetwarzanie danych, ekstrakcję cech, jak i budowę klasyfikatora dla własnych danych, symulujących ludzkie tkanki.

Problem jest rzadko poruszany w literaturze i trudno jest znaleźć artykuły dobrze odpowiadające analizowanemu problemowi. Praca [1] wprowadza metodę klasyfikacji z wykorzystaniem modelu *kNN* oraz redukcji wymiarowości. Przedstawione wyniki są stosunkowo dobre, dlatego niniejszy projekt wykorzystuje część z zastosowanych rozwiązań. Dodatkowym celem jest analiza możliwości i skuteczności redukcji szumu oraz zbadanie innych metod ekstrakcji cech. W filtracji sygnału audio może pomóc artykuł [2], podejmujący podobne zagadnienia.

1.2 Zarys ogólny proponowanego rozwiązania

Proponowany algorytm wykorzystuje klasyfikator *kNN*. Jego zastosowanie wymaga uprzedniej ekstrakcji cech oraz redukcji wymiarowości. W tym zakresie porównywane są różne metody. Zastosowanie ekstraktora cech *MFCC* oraz algorytmu *UMAP* [3] pozwala na uzyskanie na własnych danych wyników zbliżonych do pracy [1].

1.3 Wykorzystany zbiór danych

Analizowany zbiór danych składa się z nagrań dźwiękowych procesu przechodzenia igły przez symulowane tkanki. Igła umieszczona jest na ramieniu robota, wbijającego i wyciągającego igłę

z przygotowanego surogatu. Zastępcze tkanki to mięso kurczaka oraz cukinia zanurzona w żelatynie. Nagrania zostały wykonane dla 3 różnych prędkości igły oraz przy różnych konfiguracjach tkanek.
Zastosowanie zbioru do klasyfikacji wymaga podzielenia nagrań na segmenty o stałej długości reprezentujące sygnały wibroakustyczne określonych *tkanek.*

1.4 Zawartość

- W rozdziale 1. znajduje się wprowadzenie do tematu sygnałów wibroakustycznych w medycynie. Przedstawione są cele projektu z odniesieniem do istniejących prac. Wyjaśniona jest także budowa zastosowanego zbioru danych.
- Rozdział 2. przedstawia koncepcję rozwiązania, a rozdział 3. szczegółowo opisuje zastosowane metody.
- Rozdział 4. prezentuje i porównuje wyniki uzyskane w każdym etapie pracy.
- Podsumowanie wraz z wnioskami oraz możliwościami rozwoju przedstawione są w rozdziale 5.
- W dodatku A umieszczony jest odnośnik do kodu źródłowego.

2. Koncepcja proponowanego rozwiązania

W niniejszym rozdziale przedstawiona została koncepcja projektowanego rozwiązania, którego celem jest klasyfikacja materiałów dźwiękowych na podstawie ich charakterystyki akustycznej. Proces został podzielony na pięć głównych etapów: przekształcenie danych, wydobycie cech dźwięku, redukcję wymiarowości, trening modelu klasyfikacyjnego oraz ewaluację skuteczności. Na rysunku 1 przedstawiono ogólny przebieg procesu.

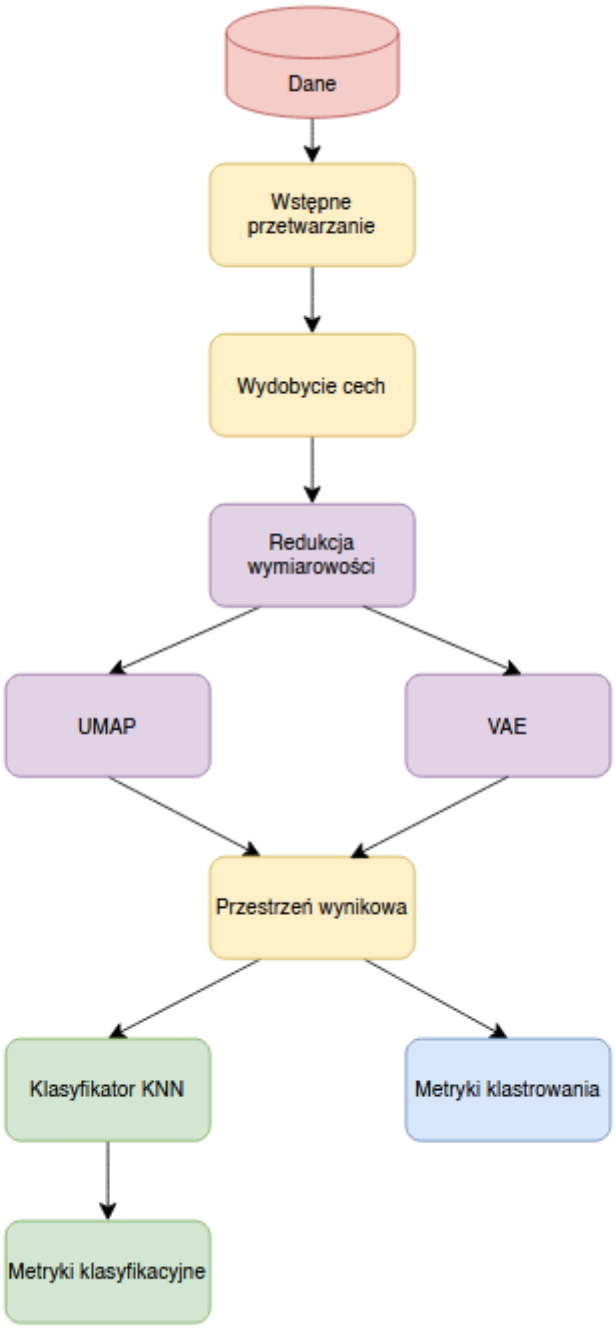

Rys. 1 Schemat blokowy procesu analizy i klasyfikacji danych dźwiękowych

2.1 Przekształcenie danych

Pierwszym etapem projektowanego rozwiązania jest wstępne przekształcenie danych wejściowych, mające na celu przygotowanie materiału dźwiękowego do dalszej analizy. Wstępna obróbka umożliwia usunięcie zakłóceń, ograniczenie zakresu częstotliwości lub pozostawienie sygnału w oryginalnej postaci – w zależności od celu analizy.

W kolejnym kroku sygnał audio jest segmentowany, a następnie selekcjonowane są jedynie te fragmenty, które spełniają kryterium stabilności pod względem głośności. Dzięki temu do dalszego etapu przetwarzania trafiają wyłącznie reprezentatywne i spójne pod względem akustycznym próbki.

2.2 Wydobycie cech dźwięku

W celu reprezentacji sygnału dźwiękowego w formie cech numerycznych wykorzystywane są współczynniki **MFCC** (Mel-Frequency Cepstral Coefficients). MFCC to powszechnie stosowana metoda analizy mowy i dźwięków, która przekształca sygnał audio w cechy uwzględniające sposób postrzegania częstotliwości przez ludzkie ucho. Proces ekstrakcji MFCC obejmuje m.in. wykonanie transformaty Fouriera, odwzorowanie na skalę Mel, logarytmowanie energii oraz dyskretną transformatę kosinusową. Uzyskane cechy dobrze reprezentują teksturę i charakterystykę dźwięków, umożliwiając ich dalszą analizę i klasyfikację.

Alternatywnie rozważano takie cechy jak **Chroma Features**, **Spectral Contrast** które lepiej sprawdzają się w analizie dźwięków tonalnych (np. muzyki), a także własnej implementacji wydobycia cech opartej na transformacji Fouriera. jednak MFCC okazały się bardziej stabilne i odporne na zakłócenia tła przy analizie krótkich, nieharmonicznych impulsów.

2.3 Redukcja wymiarowości

W eksperymentach przetestowano dwie **alternatywne** techniki redukcji wymiarów: UMAP i VAE, w celu oceny ich wpływu na reprezentację danych dźwiękowych.

- **UMAP (Uniform Manifold Approximation and Projection) -** nieliniowa metoda redukcji wymiarowości, która koncentruje się na zachowaniu lokalnej struktury danych w przestrzeni cech. Jest szybka i efektywna, dzięki czemu świetnie sprawdza się w wizualizacji danych w

przestrzeni 2D lub 3D. UMAP umożliwia obserwację klastrów oraz struktur danych dźwiękowych.

- **VAE (Variational Autoencoder) -** generatywna sieć neuronowa, która uczy się probabilistycznej reprezentacji danych w postaci tzw. przestrzeni latentnej. Składa się z kodera, dekodera oraz komponentu losowego próbkowania. W przeciwieństwie do klasycznych autoenkoderów, VAE zapewnia ciągłość przestrzeni cech, co umożliwia generowanie nowych przykładów oraz lepszą separację grup danych.

Ponadto, na etapie wyboru techniki redukcji wymiarowości, rozważano również zastosowanie **PCA (Principal Component Analysis) -** liniowa metoda analizy głównych składowych, która dobrze sprawdza się przy danych o strukturze liniowej i dużej wariancji. Jednak w przypadku cech dźwiękowych, takich jak MFCC, dane mają często **nieliniową strukturę**, co znacząco ogranicza skuteczność PCA w zachowaniu relacji między przykładami. Wizualizacje z wykorzystaniem PCA nie wykazały wyraźnych klastrów ani separacji klas.

2.4 Trening modelu

W przestrzeni cech zredukowanej przez UMAP lub VAE przeprowadzany jest trening klasyfikatora. Wybranym modelem jest **KNeighborsClassifier**, czyli klasyfikator k-najbliższych sąsiadów. Jego wybór umożliwia ocenę, czy dane audio o podobnej charakterystyce akustycznej rzeczywiście tworzą odrębne klastry. Model ten jest intuicyjny, nie wymaga intensywnego treningu, a jego skuteczność w kontekście danych dźwiękowych często okazuje się bardzo dobra.

2.5 Ewaluacja

W celu kompleksowej oceny skuteczności proponowanego rozwiązania przyjęto dwutorowe podejście: ocenę klasyfikacyjną oraz ocenę struktury przestrzeni cech.

Skuteczność klasyfikatora oceniana jest na podstawie standardowych metryk klasyfikacyjnych, pozwalających zmierzyć precyzję i trafność dokonywanych predykcji. Z kolei analiza struktury danych po redukcji wymiarowości opiera się na metrykach oceniających spójność i separację klastrów. Dzięki temu możliwe jest zarówno określenie jakości predykcji, jak i trafności reprezentacji danych w przestrzeni cech.

3. Realizacja proponowanego rozwiązania

Niniejszy rozdział przedstawia techniczne i implementacyjne aspekty stworzonego rozwiązania. Zawarto tu szczegóły dotyczące środowiska uruchomieniowego, narzędzi użytych w projekcie, implementacji poszczególnych etapów algorytmu oraz napotkanych problemów wraz z podjętymi sposobami ich rozwiązania.

3.1 Środowisko i narzędzia

Projekt został zrealizowany na komputerze z systemem operacyjnym Windows 11 z wykorzystaniem języka Python 3.10.

Główne wykorzystywane biblioteki:

- librosa - analiza dźwięku i ekstrakcja cech MFCC,
- noicereduce – usuwanie szumu tła,
- matplotlib - wizualizacje danych,
- tensorflow, keras - redukcja wymiarowości metodą VAE,
- umap-learn - redukcja wymiarowości metodą UMAP,
- numpy, scipy - przetwarzanie plików .vaw,
- scikit_learn - klasyfikacja kNN.

Minimalne wymagania sprzętowe do uruchomienia aplikacji to: 8 GB RAM, procesor czterordzeniowy, Python >= 3.8.

3.2 Implementacja poszczególnych etapów

3.2.1 Przekształcenie danych

Na pierwszym etapie przetwarzania aplikacja oferuje trzy różne tryby wstępnej obróbki danych wejściowych, które pozwalają użytkownikowi dostosować sposób przetwarzania dźwięku do konkretnego celu analizy:

- FilterMode.BANDPASS - W tym trybie stosowany jest filtr pasmowoprzepustowy (ang. bandpass filter), który umożliwia przepuszczanie wyłącznie tych częstotliwości, które mieszczą się w określonym zakresie – domyślnie między 3000 Hz a 6000 Hz, jak proponuje

praca [2]. Do implementacji użyto filtru Butterwortha siódmego rzędu, który charakteryzuje się płaską charakterystyką w paśmie przepustowym.

- FilterMode.DENOISE - Tryb ten wykorzystuje algorytm redukcji szumu reduce_noise z biblioteki *noisereduce [4]*. Każdy kanał (lewy i prawy) dźwięku stereo jest przetwarzany oddzielnie, co pozwala na bardziej precyzyjne usunięcie zakłóceń, po czym sygnał jest składany z powrotem w dwukanałową postać. Celem jest zwiększenie czytelności właściwych cech akustycznych.

- FilterMode.NONE - W tym przypadku nagrania nie są w żaden sposób modyfikowane — sygnał pozostaje w formie oryginalnej, co pozwala na analizę cech bez wstępnych przekształceń.

Po wstępnym przetworzeniu sygnał dzielony jest na krótkie segmenty o ustalonej przez użytkownika długości. Z tych segmentów wybierane są tylko te, których **średni poziom głośności (RMS)** znajduje się w zakresie jednego odchylenia standardowego od mediany całego materiału. Pozwala to skupić się na stabilnych fragmentach dźwięku i odrzucić szumy tła, ciszę oraz inne ekstremalne wartości.

W implementowanym rozwiązaniu przyjęto bazową długość segmentu równą 100 ms, co pozwala na uchwycenie krótkoterminowych cech akustycznych sygnału dźwiękowego, istotnych w kontekście analizy impulsów i innych krótkotrwałych zdarzeń akustycznych.

3.2.2 Wydobycie cech dźwięku

Dla każdego pliku dźwiękowego ekstrakcja cech realizowana jest przy użyciu biblioteki *librosa*, poprzez obliczenie współczynników MFCC (Mel-Frequency Cepstral Coefficients). Liczba współczynników może być konfigurowana w zależności od potrzeb analizy, co pozwala dostosować reprezentację danych do charakterystyki badanego materiału.

Domyślnie obliczanych jest 20 współczynników MFCC, co stanowi standardową liczbę w wielu zastosowaniach związanych z analizą sygnału mowy i dźwięków środowiskowych.

Aby ograniczyć powstawanie niepożądanych skupień w przestrzeni cech, przeprowadzono dodatkową selekcję współczynników MFCC. W eksperymentach oceniano wpływ poszczególnych

współczynników na zdolność modelu do rozróżniania klas – szczególnie w przypadkach, gdy jedna z cech znacząco wpływała na powstawanie osobnego klastra zawierającego próbki każdego z badanych materiałów. Selekcja cech pozwoliła ograniczyć ten problem, poprawiając separowalność klas w przestrzeni latentnej, jednak zmniejszyła dokładność predykcji. Opisany problem występował przy użyciu danych z dwóch kategorii (kategoria pierwsza: wbicie igły w kurczaka, a następnie w cukinię, kategoria druga: wbicie igły w cukinię, a następnie w kurczaka)

Selekcję cech przeprowadzona została w oparciu o test statystyczny ANOVA. Dla każdego współczynnika MFCC obliczono wartość p (p-value), która określa istotność statystyczną różnic pomiędzy klasami. Do dalszej analizy wybrane zostały tylko te współczynniki, których wartość p była poniżej ustalonego progu (bliskiego zeru), co wskazuje na ich istotny wpływ na różnicowanie klas. Taka selekcja okazała się szczególnie pomocna w przypadkach, w których pierwotna reprezentacja prowadziła do powstawania dwóch niejednorodnych klastrów zawierających próbki z różnych klas, które powinny być odseparowane.

3.2.3 Redukcja wymiarowości

W celu uzyskania reprezentacji danych w przestrzeni o niższej liczbie wymiarów, zastosowano dwie różne techniki: **UMAP** oraz **VAE**. Obie metody zostały zaimplementowane z możliwością dostosowania parametrów w zależności od potrzeb użytkownika.

UMAP

Algorytm UMAP zaimplementowano z użyciem biblioteki umap-learn. W eksperymentach wykorzystano następujące wartości parametrów:

- n_neighbors = 6 – liczba sąsiadów branych pod uwagę przy konstrukcji lokalnej struktury danych,
- min_dist = 0.1 – minimalny dystans między punktami w przestrzeni wynikowej,
- spread = 0.6 – wartość wpływająca na ogólną rozpiętość punktów,
- n_components – liczba wymiarów w przestrzeni docelowej możliwa do wyboru przez użytkownika.

VAE

Alternatywnym podejściem do redukcji wymiarowości był wariacyjny autoenkoder (VAE), zbudowany przy użyciu biblioteki TensorFlow oraz Keras. Architektura modelu obejmuje:

- Enkoder: warstwa gęsta o 128 neuronach z funkcją aktywacji ReLU, następnie dwie osobne warstwy gęste zwracające odpowiednio wartość średnią (z_mean) i wariancję logarytmiczną (z_log_var) rozkładu zmiennej ukrytej,

- Warstwa próbkowania: niestandardowa warstwa Sampling, która realizuje reparametryzację i generuje próbki z rozkładu normalnego,

- **Dekoder**: składający się z warstwy gęstej (128 neuronów, ReLU) oraz warstwy wyjściowej z funkcją aktywacji sigmoidalnej, rekonstruującej oryginalne dane wejściowe.

Model trenowano przy użyciu straty sumującej błąd rekonstrukcji (średni błąd kwadratowy) oraz dywergencji Kullbacka-Leiblera, z użyciem optymalizatora Adam. Po zakończeniu treningu, do uzyskania zakodowanej reprezentacji danych wykorzystano enkoder zbudowany na bazie wytrenowanego modelu. Zastosowano 50 epok i wielkość partii 32.

W przeprowadzonych eksperymentach porównano efektywność obu metod w kontekście analizy i wizualizacji danych dźwiękowych. UMAP zapewnił wyraźniejszą separację klas oraz bardziej czytelne odwzorowanie struktury danych w przestrzeni dwuwymiarowej, co znacznie ułatwiło analizę i interpretację wyników, ponadto czas wykonania był znacząco szybszy. VAE, mimo swoich zalet w modelowaniu przestrzeni latentnej, generował mniej wyraźne granice między grupami, a jego reprezentacja była bardziej rozmyta. W związku z tym, UMAP został uznany za bardziej odpowiednią metodę redukcji wymiarowości w tym zadaniu.

3.2.4 Trening modelu

Model klasyfikatora K najbliższych sąsiadów (KNN) został wykorzystany jako końcowy element procesu klasyfikacji.

Model KNN nie wymaga procesu trenowania w klasycznym sensie (brak fazy uczenia wag), lecz opiera się na obliczaniu metryki odległości (użyto metryki euklidesowej) pomiędzy punktami w przestrzeni o zredukowanej wymiarowości (po zastosowaniu UMAP lub VAE). Dzięki temu

klasyfikator ten dobrze współgra z metodami redukcji wymiarowości, które uwypuklają ukrytą strukturę danych.

3.2.5 Ewaluacja

Skuteczność modelu klasyfikacyjnego oceniana jest za pomocą kilku podstawowych metryk:

- **Dokładność (accuracy)** – stosunek liczby poprawnie sklasyfikowanych przykładów do całkowitej liczby przypadków,

- **Czułość (recall)** – zdolność modelu do wykrywania pozytywnych przypadków,

- **F1-score** – zharmonizowana średnia precyzji i recall.

Metryki te odnoszą się bezpośrednio do jakości predykcji dokonywanych przez klasyfikator (w naszym przypadku KNeighborsClassifier).

Dodatkowo, do oceny struktury i separowalności danych w przestrzeni cech po redukcji wymiarowości (np. po zastosowaniu UMAP) wykorzystujemy metryki klastrowania:

- **Silhouette Score** – mierzy, jak dobrze dane punkty pasują do swojego klastra, biorąc pod uwagę odległości między punktami w klastrze i między klastrami,

- **Davies-Bouldin Index** – ocenia jakość klastrowania na podstawie stosunku odległości między klastrami do ich rozrzutu.

Wspólne zastosowanie metryk klasyfikacyjnych oraz klastrowych pozwala ocenić zarówno jakość predykcji, jak i strukturę danych w przestrzeni cech.

3.3 Napotkane problemy

1. **Zakłócenia i skoki sygnału dźwiękowego** - Jednym z pierwszych problemów była obecność zakłóceń oraz nagłych skoków amplitudy sygnału w momencie przejścia igły przez materiał. Zjawisko to prowadzi do znacznych odchyleń od charakterystyki akustycznej próbki. W celu jego wyeliminowania zastosowano procedury odszumiania oraz selekcję fragmentów sygnału, których średnia energia (RMS) mieściła się w granicach jednego odchylenia standardowego od mediany całego sygnału.

2. **Ekstrakcja cech akustycznych** - Pierwotnie cechy akustyczne były pozyskiwane za pomocą autorskiej metody bazującej na dyskretnej transformacie Fouriera oraz przekształceniach logarytmicznych. Jednak uzyskane w ten sposób reprezentacje nie zapewniały wystarczającej separowalności klas. W związku z tym zdecydowano się na wykorzystanie gotowych, dobrze udokumentowanych funkcji ekstrakcji cech z biblioteki Librosa, w tym współczynników MFCC, które umożliwiły kompleksowe i skuteczne odwzorowanie charakterystyki dźwięku.

3. **Tworzenie się niepoprawnych klastrów międzyklasowych** - Jednym z największych wyzwań okazało się występowanie klastrów zawierających próbki należące do różnych klas materiałów (separacja powstawała przy badaniu próbek z różnymi położeniami materiałów). Mimo licznych prób doboru parametrów metod redukcji wymiarowości, problem ten utrzymywał się, prowadząc do zatarcia granic między klasami. Wnikliwa analiza wykazała, że przyczyną były współczynniki MFCC nr 4 i 5, które silnie wpływały na podobieństwo sygnałów pochodzących z różnych klas. W konsekwencji podjęto decyzję o selekcji cech na podstawie ich zdolności do separacji klas (m.in. poprzez analizę wartości p-value), przed przystąpieniem do redukcji wymiarowości metodą UMAP. Znacząco zmniejszyło to jednak dokładności predykcji, jednak wyeliminowało niepoprawne klastry. Jest to więc możliwa ścieżka rozwoju projektu.

4. **Dobór parametrów modelu** - Jak w przypadku większości projektów analitycznych, wyzwaniem był także dobór optymalnych parametrów dla poszczególnych etapów przetwarzania – w szczególności dla redukcji wymiarowości i klasyfikacji.

4. Rezultaty i wnioski

W rozdziale przedstawiono wyniki kolejnych etapów pracy.

4.1 Wizualizacja danych i redukcja szumu

Na rysunkach 2 i 3 przedstawiono przykładowe nagrania ze zbioru danych. Kolorowe pasy wyznaczają czas, w którym igła przechodziła w głąb określonych tkanek. Związek między amplitudą sygnału, a rodzajem ośrodka jest bardzo trudno dostrzegalny, a sygnały różnią się między sobą, mimo przeprowadzania eksperymentów w tych samych warunkach. Widoczny skok amplitudy w pierwszej sekundzie to sztuczny dźwięk synchronizujący, nieprzydatny w naszej analizie.

Dodatkowo, rysunek 2 obrazuje efekt zastosowania filtru pasmowo-przepustowego Butterwortha o parametrach zgodnych z zastosowanymi w pracy [2]. Na rysunku 3 widoczny jest efekt działania biblioteki *noisereduce* [4].

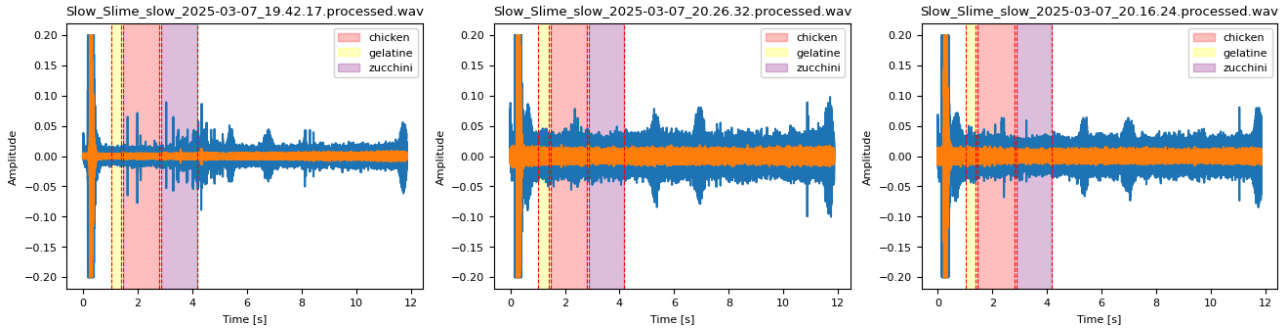

Rys. 2 Przykładowe elementy ze zbioru danych z zaznaczonymi czasami przechodzenia igły przez tkanki. Niebieski wykres wskazuje oryginalną ścieżkę dźwiękową, a pomarańczowy, dźwięk po zastosowaniu filtru pasmowo-przepustowego.

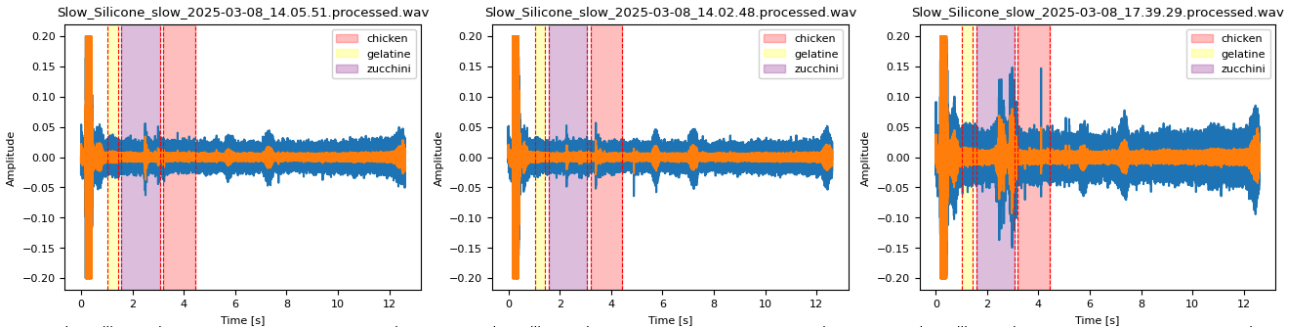

Rys. 3 Przykładowe elementy ze zbioru danych z zaznaczonymi czasami przechodzenia igły przez tkanki. Pomarańczowy wykres obrazuje ścieżkę audio po zastosowaniu redukcji szumu (noisereduce [4]).

4.2 Dobór metod i parametrów

W celu określenia ostatecznego rozwiązania należy dokonać wyboru metody ewentualnego odszumiania, ekstrakcji cech oraz redukcji wymiarowości

Analizowane metody ekstrakcji cech to MFCC oraz proponowana metoda w pracy [1]. Rys. 4 pokazuje, że MFCC pozwala na wyraźniejszą separację tkanek, co przełoży się na lepszy wynik klasyfikatora *kNN*.

Filtrowanie oraz odszumianie sygnałów nie przyniosło oczekiwanych efektów (rys. 5). Dźwięk filtrowany za pomocą filtra pasmowo-przepustowego nie nadaje się do dalszej analizy, a odszumianie przy pomocy biblioteki *noisereduce* nie przynosi poprawy względem rys. 4.

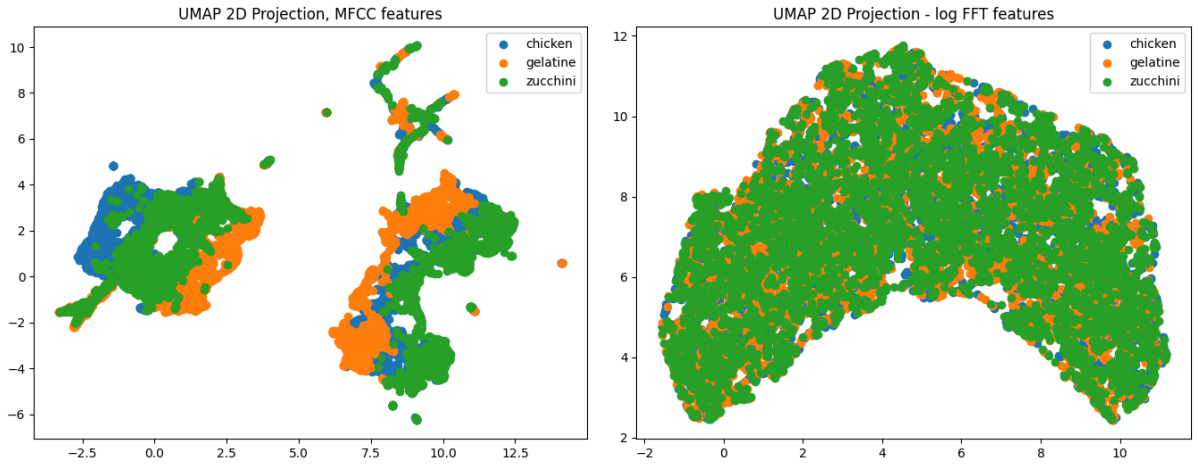

Rys. 4 Wizualizacja rezultatu redukcji do 2 wymiarów przy pomocy UMAP dla różnych metod ekstrakcji cech

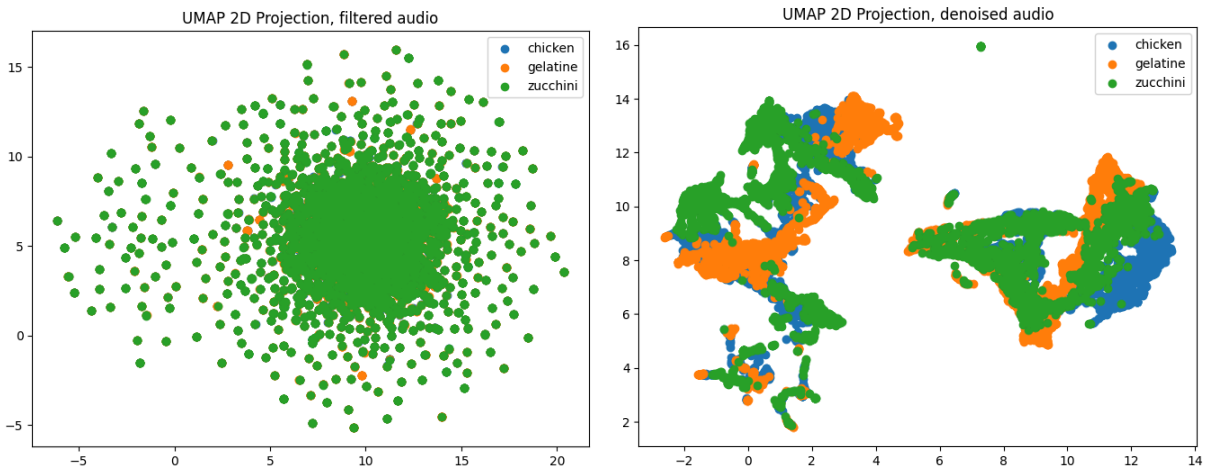

Rys. 5 Wizualizacja wyników redukcji wymiarów przy pomocy UMAP dla sygnału filtrowanego oraz odszumionego przy pomocy noisereduce [4]

Wynik dla redukcji wymiarów przy użyciu VAE widoczny na rys. 6 nie jest zadowalający. Przeprowadzenie udanej klasyfikacji dla takich danych nie będzie możliwe.

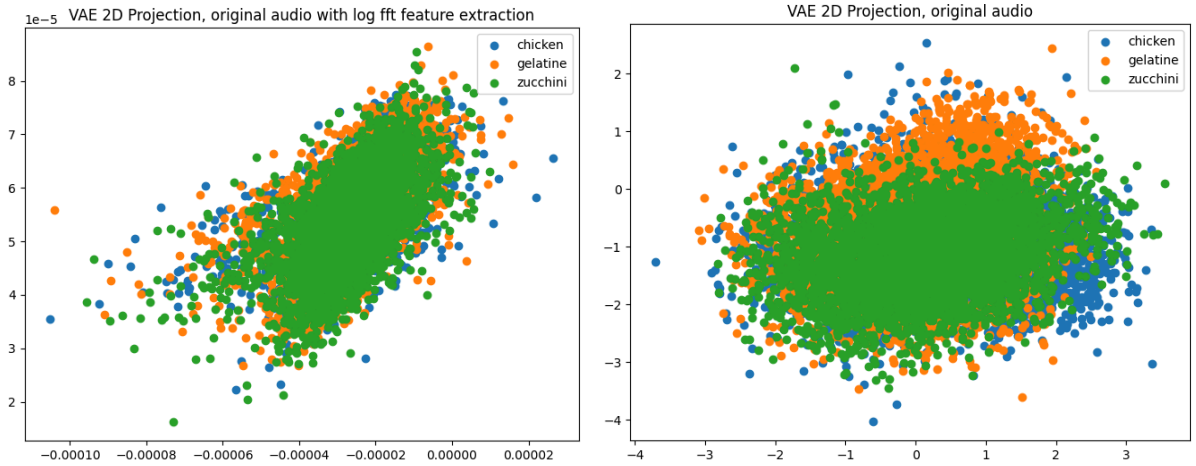

Rys. 6 Wymiary zredukowane przy użyciu VAE dla różnych metod ekstrakcji cech

Kluczowymi dla działania systemu parametrami jest wartość *k* w algorytmie *kNN* oraz liczba zredukowanych wymiarów dla której uruchamiamy klasyfikator. Praca [1] sugeruje *k=2* oraz dwuwymiarową redukcję. Wykresy 7, 8, 9 pokazują, że w przypadku naszych danych takie wartości nie są optymalne.

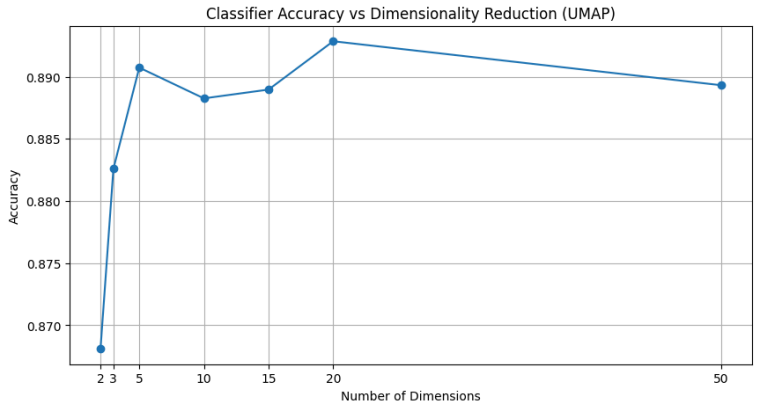

Rys. 7 Osiągane wartości accuracy w zależności od liczby wymiarów

Jak widać na rys. 7, *kNN* osiąga najlepszą dokładność dla 5 oraz 20 wymiarów. Dla uproszczenia modelu przyjmujemy najlepszą wartość jako 5. Rysunki 8 i 9 przedstawiają zależność wskaźników sylwetkowego oraz *Daviesa-Bouldina* od parametru *k.* Wartości w okolicy 12 wydają się być dobrym wyborem.

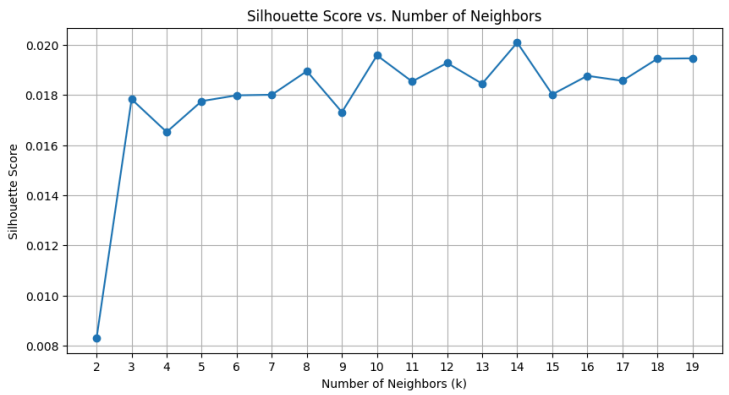

Rys. 8 Wskaźnik sylwetkowy dla różnych k

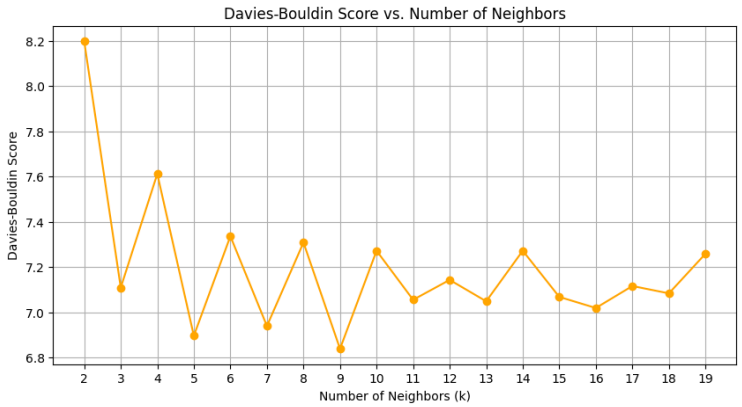

Rys. 9 Wskaźnik Daviesa-Bouldina dla różnych k

4.3 Ewaluacja modelu

Przeprowadzono ostateczną ewaluację modelu dla dobranego parametru $k = 12$ oraz 5 wymiarów. Uzyskano wartość dokładności na poziomie 88% dla zbioru testowego. Skuteczność 2 najbardziej znaczących komponentów po redukcji wymiarowości przy użyciu *UMAP* pokazuje rys. 10. Macierz błędów widoczna na rys. 11 wskazuje że klasyfikator stosunkowo dobrze poradził sobie z problemem, choć występują problemy z odróżnieniem cukinii od kurczaka.

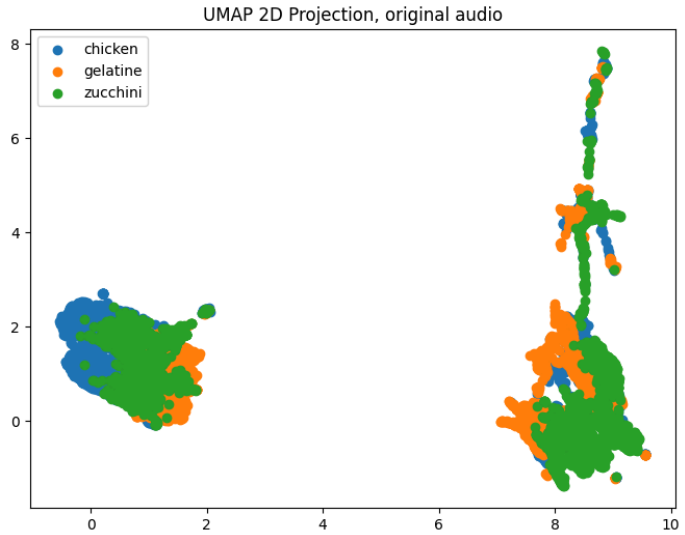

Rys. 10 Wizualizacja 2 najistotniejszych komponentów po redukcji do 5 wymiarów

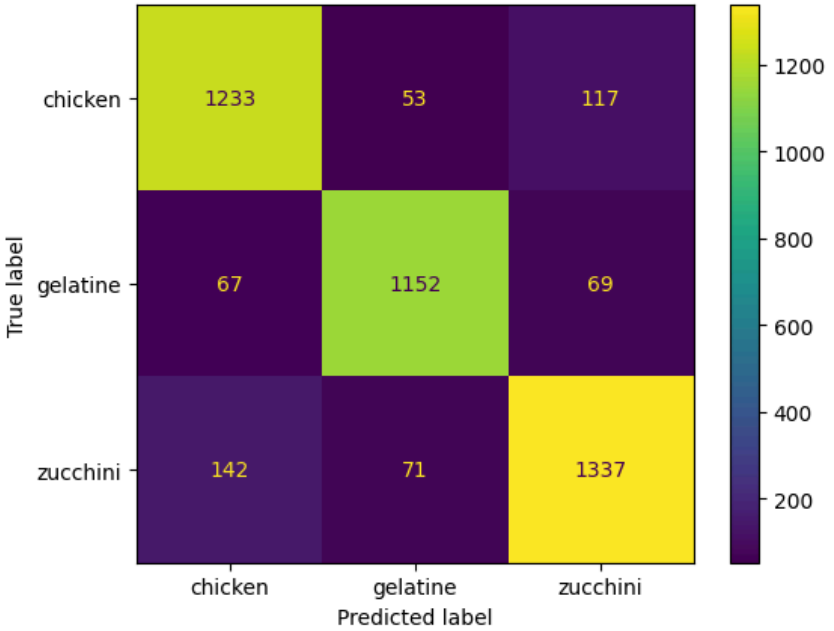

Rys. 11 Macierz błędów dla zbioru testowego - kNN

W celu oceny rezultatu, przeprowadzono próbę nauczenia klasyfikatora *SVM* z wykorzystaniem tej samej ekstrakcji cech i bez redukcji wymiarowości. Uzyskano 76% dokładności na zbiorze testowym. Problemy z rozróżnieniem klas reprezentujących tkanki stałe są dużo bardziej widoczne (rys. 12).

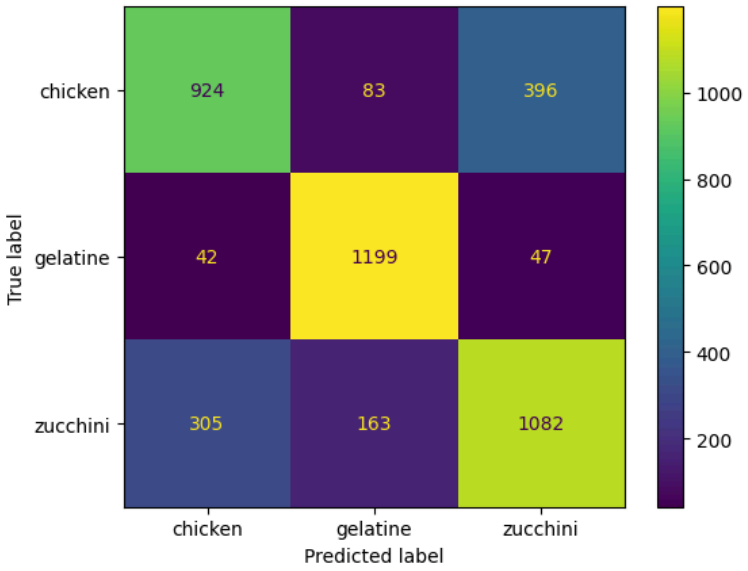

Rys. 12 Macierz błędów dla zbioru testowego - SVM

4.4 Wnioski

Uzyskano zadowalające rezultaty, mimo rozczarowującego działania niektórych metod proponowanych w pracy [1]. Udało się znaleźć alternatywę dla ekstrakcji cech oraz dobrać lepsze parametry. Przewaga analizowanego podejścia jest widoczna po porównaniu z modelem SVM, który radzi sobie wyraźnie gorzej.

Problemem jest trudno wyjaśnialny podział na 2 główne grupy widoczny na rys. 4 oraz 10. Może mieć na niego wpływ konfiguracja kolejności przebijanych tkanek.

5. Podsumowanie

Cele i założenia projektu zostały osiągnięte. Uzyskany wynik, choć pozostawia pole do poprawy, jest satysfakcjonujący i nie odbiega znacząco od osiągnięć artykułu [1]. Porównanie z *SVM* pokazało, że podejście wykorzystujące redukcję wymiarowości przynosi zauważalne korzyści.

Elementem, który może zostać rozwinięty jest przetwarzanie wstępne sygnału dźwiękowego. Odszumianie sygnału tak aby nie zaburzyć pożądanych sygnałów wibroakustycznych jest dużym wyzwaniem i dalsza praca w tym zakresie wymaga specjalistycznej wiedzy dotyczącej dźwięku. Analizowane metody redukcji szumu zawiodły. Szczególnie rozczarowująca okazała się użycie filtru Butterwortha dobrze działającego w pracy [2] – prawdopodobnie powodem jest odmienny cel filtracji.

Problemem okazała się metoda ekstrakcji cech oraz redukcja wymiarowości za pomocą *VAE,* które zadowalająco działały w pracy [1], a dla naszych danych okazały się nieodpowiednie. Być może spowodowały to właśnie różnice w zbiorze danych lub szczegóły implementacyjne algorytmów. Problem został rozwiązany poprzez wykorzystanie alternatywnego algorytmu ekstrakcji cech. Również redukcja wymiarowości metodą *UMAP,* nie daje łatwych do interpretacji wyników, co utrudnia proces doboru parametrów.

Wyniki projektu dowodzą że klasyfikacja tkanek na podstawie sygnałów wibroakustycznych jest możliwa. Wykorzystanie do rzeczywistych zastosowań wymaga jednak dalszej pracy. Należy zbadać jak proponowany poradzi sobie z docelowymi tkankami i opracować lub pozyskać odpowiedni zbiór danych. Kolejnym krokiem naprzód byłoby połączenie sygnałów wibroakustycznych z analizą obrazu USG. Poza zbiorem danych, występuje tu jednak problem z synchronizacją audio-wideo.

Bibliografia

[1] Urrutia, Robin, et al. "Exploring Deep Clustering Methods in Vibro-Acoustic Sensing for Enhancing Biological Tissue Characterization." *IEEE Access* (2025).

[2] Sabieleish, Muhannad, et al. "Study of needle punctures into soft tissue through audio and force sensing: can audio be a simple alternative for needle guidance?." *International Journal of Computer Assisted Radiology and Surgery* 16 (2021): 1683-1697.

[3] McInnes, Leland, John Healy, and James Melville. "Umap: Uniform manifold approximation and projection for dimension reduction." *arXiv preprint arXiv:1802.03426* (2018).

[4] Sainburg, Tim. "timsainb/noisereduce: v1. 0." *Zenodo, Jun* (2019).

DODATEK A: Kod źródłowy

- **github:** https://github.com/MartynaSokolowska/Vibroacoustic-analysis